Compiladores - Projecto

iJava

João Ricardo Lourenço, Nº 2011151194 Joaquim Pedro Bento Gonçalves Pratas Leitão, Nº 2011150072

30 de Maio de 2014

Relatório

${\rm \acute{I}ndice}$

1	Intr	rodução	3
2	Ana	álise Lexical	5
	2.1	Tokens	5
	2.2	Comentários	
		Tratamento de Erros Lexicais	
3	Ana	álise Sintática	9
	3.1	Gramática	10
		3.1.1 Ambiguidade	11
		3.1.2 Alterações à Gramática Fornecida	11
4	Cor	nstrução da Árvore de Sintaxe Abstrata	12
5	Ana	álise Semântica	13
	5.1	Tabelas de Símbolos	13
		5.1.1 Criação das Tabelas de Símbolos	13
		5.1.2 Implementação	14
		5.1.3 Conclusão	15
	5.2	Deteção de Erros Semânticos	16
6	Ger	ração de Código	17
7	Apı	reciação do Trabalho	18

1 Introdução

O presente trabalho pretende-se desenvolver um compilador para a linguagem iJava, um pequeno subconjunto da linguagem Java (versão 5.0). Por ser um subconjunto de uma outra linguagem, todos os programas que respeitem as regras impostas em iJava são também, garantidamente, programas válidos em Java.

Nesta linguagem todos os programas são constituídos por uma única classe, que possui métodos e atributos estáticos, e públicos. Para além disso, a classe necessita obrigatoriamente de ter um método main, onde a execução do programa se inicia.

Podemos utilizar literais dos tipos inteiro e booleano e variáveis inteiras, booleanas e arrays uni-dimensionais de inteiros e booleanos.

A linguagem implementa também expressões aritméticas e lógicas, operações relacionais simples, instruções de atribuição e controlo $(if - else \ ewhile)$.

Os métodos definidos, e os respetivos valores de retorno, podem podem ser de qualquer tipo acima mencionado, com exceção do método main, que tal como em Java possui como tipo de retorno o tipo void.

É também possível passar parâmetros (literais inteiros) ao nosso programa através da linha de comandos. É o método main que vai receber esses parâmetros, armazenando-os num array de objetos do tipo String. Embora este tipo de dados não esteja incluído na lista de tipos permitidos em iJava, a sua utilização apenas é permitida no método main, com a mera finalidade de obter os parâmetros passados ao programa aquando da sua invocação.

O desenvolvimento do compilador foi dividido em três fases distintas.

Numa primeira fase foi realizada a *Análise Lexical* do programa fonte, onde são identificados *tokens*, isto é, cadeias pertencentes à linguagem e que têm significado e relevância para o programa.

Seguiu-se a $An\'{a}lise$ $Sem\^{a}ntica$, composta por quatro etapas principais: FIXME, MUDAR A MANEIRA COMO ESTAMOS A DIZER O QUE SE SEGUE

- Tradução da gramática-fonte (fornecida em notação EBNF) para o yacc 3 e realização da Análise Sintática do programa, permitindo assim reconhecer se as sequências de tokens que o constituem pertencem à linguagem, permitindo-nos assim detetar eventuais erros de sintaxe.
- Construção da árvore de sintaxe abstrata, etapa que é realizada em simultâneo com a Análise Sintática. A árvore de sintaxe abstrata irá representar o nosso programa a compilar, recorrendo a uma estrutura em árvore para representar as estruturas sintáticas das cadeias que constituem o programa a compilar.

- Construção da tabela de símbolos, utilizadas para armazenar informações relevantes sobre a classe (seus atributos e métodos), bem como sobre cada método definido pelo programador (como, por exemplo, o tipo de retorno e os argumentos).
- Verificação de erros semânticos, etapa principal da Análise Semântica, onde são realizadas verificações de tipos, garantindo que para cada operação a realizar não existem incompatibilidades de tipos entre os operandos nela envolvidos.

A última fase do trabalho consistiu na Geração de C'odigo Interm'edio, da qual resulta, na representação interm\'edia de LLVM, um programa equivalente ao que pretendemos compilar.

METER IMAGEM BONITINHA, TIPO CACEIRO???

2 Análise Lexical

Tal como referimos anteriormente, na $Análise\ Lexical\$ procedemos à identificação dos tokens da nossa linguagem. Para isso utilizámos a ferramenta lex, responsável por gerar analisadores lexicais para linguagens.

Assim, no nosso analisador, sempre que é detetada a presença de um comentário no programa a compilar, seja do tipo //... (comentários de apenas uma linha) ou do tipo /*...*/ (comentários multi-linha), os caracteres incluídos nesse comentário são ignorados.

Sempre que é detetado um caracter, ou uma sequência de caracteres, que não constitui nenhum *token* é detetado um erro lexical, sendo impressa uma mensagem de erro, indicando a existência de um caracter ilegal, juntamente com a sua posição no programa.

Adicionalmente, caso se verifique a ocorrência de um comentário multilinha que não foi devidamente terminado, o erro lexical é também detetado, sendo impressa uma mensagem de erro que indica a posição no programa onde o comentário foi iniciado.

2.1 Tokens

Em seguida, apresentamos a lista dos tokens válidos na linguagem iJava e a lista dos tokens reservados que, por essa razão, não estão disponíveis na nossa linguagem:

- ID: Sequências alfanuméricas (maiúsculas e minúsculas) começadas por uma letra, podendo conter também símbolos como "_" e "\$". Este token pode também ser descrito na forma da sua expressão regular: letra(letra-[0-9])*, sendo o token letra da nossa autoria, definido por: $[a-z] \mid [A-Z] \mid "_"$ \$"
- INTLIT: Sequências de dígitos decimais e hexadecimais (incluindo a-f e A-F) precedidas de 0x. Este token pode também ser descrito na forma da seguinte expressão regular: [0-9]+-0x[0-9a-fA-F]+
- **BOOLLIT**: true | false
- **INT**: *int*
- BOOL: boolean
- **NEW**: new
- **IF**: *if*
- ELSE: else
- WHILE: while

- ullet **PRINT**: System.out.println
- ullet PARSEINT: Integer.parseInt
- CLASS: class
- PUBLIC: public
- ullet STATIC: static
- VOID: void
- STRING: String
- **DOTLENGTH**: .length
- **RETURN**: return
- OCURV: (
- CCURV:)
- OBRACE: {
- CBRACE: }
- OSQUARE: [
- CSQUARE:]
- OP1: && |||
- **OP2**: <|>|==|! =|<=|>=
- **OP3**: "+" | -"
- **OP4**: " * " | "/" | "%"
- NOT: "!"
- **ASSIGN**: " = "
- **SEMIC**: ";"
- **COMMA**: ","
- RESERVED: abstract | continue | for | switch | assert | default | goto | package | synchronized | do | private | this | break | double | implements | protected | throw | byte | import | throws | case | enum | instanceof | transient | catch | extends | short | try | char | final | interface | finally | long | strictfp | volatile | const | float | native | super | null | ++ | --

Para além dos *tokens* apresentados, definimos outros *tokens*, que passamos a especificar:

- WHITESPACE: Token correspondente ao caracter de espaço em branco
- **OPEN_COMMENT**: *Token* correspondente ao início de um comentário multi-linha, /*
- CLOSE_COMMENT: Token correspondente ao fecho de um comentário multi-linha, */
- SINGLE_LINE_COMMENT: Token utilizado para detetar a ocorrência de um comentário de uma linha apenas

Quando implementámos a Análise Sintática, para resolver problemas de ambiguidade da gramática foi necessário, entre outras ações que iremos abordar na próxima secção, separar os tokens **OP1**, **OP2**, **OP3** e **OP4** nas diferentes sequências alfanuméricas que os constituíam. Assim, temos ainda os seguintes tokens:

- AND ("&&") e OR ("||"), originados a partir do token OP1
- LE («"), GE (»"), EQ ("=="), NEQ ("!="), LEQ («=") e GEQ (»="), originados a partir do token OP2
- PLUS ("+") e MINUS (-"), originados a partide do token OP3
- MULT ("*"), DIV ("/") e MOD ("%"), originados a partir do token OP4

2.2 Comentários

Para identificarmos a ocorrência de comentários nos programas a compilar recorremos aos $tokens\ OPEN_COMMENT,\ CLOSE_COMMENT$ e $SINGLE_LINE_COMMENT.$

Quando detetamos o $token\ OPEN_COMMENT$ é criado um novo estado no analisador, que indica a existência de um comentário multi-linha. A esse estamos demos o nome $MULTI_LINE_COMMENT_S$.

Uma vez neste estado, todos os caracteres e tokens identificados são ignorados, com exceção do token de fecho do comentário multi-linha ($CLOSE_COMMENT$) e do token de fim do ficheiro, << EOF >>, disponível na ferramenta utilizada para desenvolver o analisador (lex).

Caso seja identificado o token CLOSE_COMMENT, o estado do analisador é reposto, passando este a ter o seu estado por defeito.

Por outro lado, se for detetado << EOF>> temos uma situação em que um comentário multi-linha não foi devidamente terminado, pelo que é gerado um erro lexical, terminando a execução do analisador e sendo o utilizador informado da ocorrência do erro e da localização no programa fornecido do comando que inicia o comentário.

Se, por alguma razão, o token CLOSE_COMMENT for identificado quando o analisador não se encontra no estado MULTI_LINE_COMMENT_S é detetada a ocorrência de um erro lexical, uma vez que na nossa linguagem não é possível a existência do comando */ sem que antes tenha sido colocado um /*. Mais uma vez, assim que o erro lexical é detetado o utilizador é informado com uma mensagem que indica a posição no programa onde se deu o erro, e o analisador termina a sua execução.

Ao detetarmos o token SINGLE_LINE_COMMENT vamos ignorar todos os caracteres e tokens que se lhe seguirem, até que seja reconhecido o token de mudança de linha (NEWLINE). Desta forma estamos a descartar toda a restante linha do programa, após a ocorrência de \\, tal como seria desejado proceder no tratamento de comentários de uma linha apenas.

2.3 Tratamento de Erros Lexicais

Tal como referimos nos pontos anteriores, sempre que o analisador desenvolvido deteta a ocorrência de um erro lexical (seja por existência de um token não permitido ou por não término de um comentário multi-linha), é impressa uma mensagem de erro que indica a posição do erro no programa a compilar (indicando a linha e coluna onde o erro ocorreu).

Quando é detetado um caracter ilegal, o analisador imprime a mensagem de erro, prosseguindo a sua execução na linha seguinte do programa a compilar até ser lido todo o conteúdo do programa.

Tendo sido detetada a ocorrência de um ou mais erros lexicais, após ler todo o programa, o analisador termina a sua execução, não sendo realizado mais nenhum passo da compilação.

3 Análise Sintática

A Análise Lexical permite-nos identificar os *tokens* da linguagem, isto é, os seus "átomos". No entanto, interessa-nos garantir que os *tokens* identificados estão organizados de acordo com a estrutura sintática da linguagem.

Para validar essa organização dos tokens necessitamos de utilizar uma gramática, que nos indica como devem estar organizados sintaticamente os tokens da linguagem. Para além disso, utilizámos a ferramenta YACC (Yet Another Compiler Compiler), um gerador de analisadores sintáticos.

Assim, utilizamos o analisador lexical (lex) desenvolvido para reconhecer os tokens da linguagem, que são transferidos para o yacc onde, com base na gramática da linguagem fornecida, podemos verificar se o programa a compilar se encontra organizado de acordo com a estrutura sintática da linguagem.

No analisador sintático foi criada uma *union*, que define a estrutura de uma variável *yylval*, utilizada na comunicação entre o *yacc* e o *lex*. Apresentamos desde já a estrutura da *union* criada:

```
%union
{
    char* token;
    struct _node_t* node;
    int type;
}
```

Os token detetados no lex são comunicados ao analisador sintático através do campo token da variável yylval.

Para além disso, no analisador sintático definimos ainda três variáveis externas, para uso partilhado entre o lex e o yacc: Duas do tipo inteiro, prev_col e prev_line, e uma do tipo array de caracteres (char*), chamada yytext e que contém a cadeia de caracteres lida pelo analisador, em cada momento.

Tal como o nome pode sugerir, prev_col e prev_line são utilizadas para armazenar o valor da coluna e linha (do programa a compilar) analisadas na iteração anterior da execução do analisador. A justificação para essa prende-se com as situações onde ocorrem erros sintáticos, sendo necessário informar o utilizador da localização no programa desse erro.

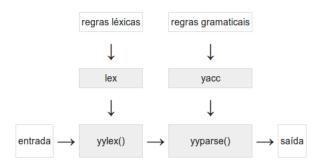


Figura 1: Ligação entre o lex e o yacc, ferramentas utilizadas para gerar os analisadores lexicais e sintáticos. Retirado de http://pt.wikipedia.org/wiki/Yacc

3.1 Gramática

De seguida, apresentamos a gramática da linguagem iJava, fornecida no enunciado do projeto, em notação **EBNF**:

 $Start \to Program$

 $Program \rightarrow CLASS ID OBRACE FieldDecl | MethodDecl CBRACE$

 $\mathrm{FieldDecl} \to \mathrm{STATIC}\ \mathrm{VarDecl}$

 $MethodDecl \rightarrow PUBLIC STATIC (Type | VOID) ID OCURV$

[FormalParams] CCURV OBRACE VarDecl Statement CBRACE

FormalParams \rightarrow Type ID COMMA Type ID

Formal Params \rightarrow STRING OSQUARE CSQUARE ID

 $VarDecl \rightarrow Type ID COMMA ID SEMIC$

Type \rightarrow (INT | BOOL) [OSQUARE CSQUARE]

 $Statement \rightarrow OBRACE$ Statement CBRACE

 $Statement \rightarrow IF OCURV Expr CCURV Statement [ELSE Statement]$

Statement → WHILE OCURV Expr CCURV Statement

 $Statement \rightarrow PRINT OCURV Expr CCURV SEMIC$

 $Statement \rightarrow ID$ [OSQUARE Expr CSQUARE] ASSIGN Expr SEMIC

Statement \rightarrow RETURN [Expr] SEMIC

 $\text{Expr} \rightarrow \text{Expr}$ (OP1 | OP2 | OP3 | OP4) Expr

 $\operatorname{Expr} \to \operatorname{Expr} \operatorname{OSQUARE} \operatorname{Expr} \operatorname{CSQUARE}$

 $Expr \rightarrow ID \mid INTLIT \mid BOOLLIT$

 $\operatorname{Expr} \to \operatorname{NEW}$ ($\operatorname{INT} \mid \operatorname{BOOL}$) OSQUARE Expr CSQUARE

 $Expr \rightarrow OCURV Expr CCURV$

 $\operatorname{Expr} \to \operatorname{Expr} \operatorname{DOTLENGTH} \mid$ ($\operatorname{OP3} \mid \operatorname{NOT}$) Expr

 $\operatorname{Expr} \to \operatorname{PARSEINT}$ OCURV ID OSQUARE Expr CSQUARE CCURV

 $\text{Expr} \rightarrow \text{ID OCURV}$ [Args] CCURV

 $Args \rightarrow Expr$ COMMA Expr

Lembramos que, em notação **ENBF**, os símbolos [...] englobam tokens opcionais e $\{...\}$ implicam a repetição dos tokens 0 ou mais vezes.

3.1.1 Ambiguidade

Um análise mais cuidada da gramática apresentada permite-nos aferir da sua ambiguidade. Por exemplo, se num dado momento da análise sintática pretendermos analisar 2+3*5, podemos reduzir esta expressão à variável EXPR da gramática por duas formas distintas:

- 1. Numa primeira abordagem podemos separar a expressão em Expr → Expr + Expr (onde o símbolo "+" é proveniente do token OP3). De seguida reduziríamos o primeiro símbolo Expr para o token INTLIT correspondente, neste caso, ao literal "2". O segundo símbolo Expr seria desdobrado em Expr → Expr * Expr (onde o símbolo "*" é proveniente do token OP4). Neste caso os dois símbolos Expr seriam reduzidos ao token INTLIT, correspondente a cada um dos restantes literais.
- Numa abordagem alternativa começaríamos por separar a expressão em Expr → Expr * Expr. De seguida desdobraríamos o primeiro símbolo Expr em Expr → Expr + Expr. Estes dois novos símbolos Expr seriam reduzidos a INTLIT, tal como o restante símbolo Expr.

Acabámos de provar a ambiguidade da gramática. Tal como esta situação existem muitas outras envolvendo os operadores englobados pelos tokens OP1, OP2, OP3 e OP4. Assim, é imperativa a definição de prioridades nos operadores, de forma a eliminar todas as ambiguidades presentes na gramática, permitindo assim a correta realização da análise sintática do programa.

3.1.2 Alterações à Gramática Fornecida

Uma vez que a gramática apresentada é ambígua e apresenta-se em notação **EBNF**, não aceite pela ferramenta utilizada para gerar o analisador sintático, necessitamos de alterar a gramática, de forma a eliminar as suas ambiguidades, tornando-a numa gramática aceite pela ferramenta utilizada.

Como já referimos, a primeira alteração realizada prende-se com a separação dos operadores englobados pelos tokens OP1, OP2, OP3 e OP4, criando um novo token para cada operador.

FIXME: METER AQUI AS PRIORIDADES DOS OPERADORES FIXME: METER ALTERAÇÕES FEITAS À GRAMÁTICA. EXPLI-CAR QUAIS AS ALTERAÇÕES E PORQUE É QUE AS FIZEMOS

4 Construção da Árvore de Sintaxe Abstrata

FIXME: METER AQUI TAMBÉM O CÓDIGO: ESTRUTURA NODE_T E OS TIPOS E ENUM'S PRESENTES NO NODE_T.H EXPLICAR AS ESTRUTURAS UTILIZADAS E O PORQUE DE TERMOS ESCOLHIDO ESTAS ESTRUTURAS. (PODERÍAMOS TER FEITO MELHOR? MUDARÍAMOS ALGUMA COISA?)

5 Análise Semântica

Até esta fase da compilação os passos executados, estruturas criadas, etc tinham como principal objetivo certificar que o programa, de facto, estava escrito na linguagem iJava adotada.

Na fase da $Análise\ Semântica$ pretendemos estender esse estudo, procurando aferir se as instruções que constituem o programa possuem, de facto, algum significado em iJava.

Assim, nesta fase da compilação, a principal preocupação irá recair sobre as operações a realizar indicadas no programa, verificando a compatibilidade dos tipos de dados envolvidos nestas. Nesse sentido necessitamos de criar um estrutura que, de alguma forma, nos permita armazenar e consultar as variáveis (e os respetivos tipos) a que podemos aceder a partir de uma qualquer zona do programa.

Para tal, foi necessário criar e implementar *Tabelas de Símbolos*, que nos permitem aceder a essas mesmas informações. Desta forma podemos verificar os tipos dos dados envolvidos nas diversas operações que constituem o programa, detetando eventuais situações de incompatibilidade entre tipos, inválidas nos programas.

5.1 Tabelas de Símbolos

Uma $Tabela\ de\ Símbolos$ (ou um Ambiente) é, como já referimos, uma estrutura de dados que mapeia identificadores com os seus tipos e localizações.

Como a nossa linguagem apenas permite a execução de programas com uma única classe, que possui métodos e atributos estáticos e públicos, necessitamos de conhecer todos os métodos e atributos que compõem a classe, bem como as variáveis definidas em cada um dos métodos.

Desta forma podemos facilmente detetar situações em que são invocados métodos não declarados na classe, ou em que são utilizados atributos não definidos na classe ou para o método no qual se pretende utilizar o atributo.

Por estas razões mantemos uma *Tabela de Símbolos* para a classe na qual está contido o programa, sendo também mantida uma *Tabela de Símbolos* para cada método definido para a classe.

5.1.1 Criação das Tabelas de Símbolos

Cada Tabela de Símbolos é criada a partir da Árvore de Sintaxe Abstrata, construída na etapa anterior da compilação.

Assim, para a criação da Tabela de Símbolos da classe do programa, percorremos os nós da $\'{A}rvore$ de Sintaxe Abstrata relativos às declarações de atributos e métodos, criando uma nova entrada na tabela para cada método

ou atributo declarado, na qual se armazenam o nome do método ou atributo declarado.

No caso da entrada corresponder a um atributo é também armazenado o tipo do atributo. Caso a entrada corresponda à declaração de um método é guardado uma referência para a *Tabela de Símbolos* do método.

Na criação da *Tabela de Símbolos* de um método da classe percorremos os nós da *Árvore de Sintaxe Abstrata* relativos às instruções que compõem o método, criando na sua *Tabela de Símbolos* uma entrada onde armazenamos o seu nome, outra onde é armazenado o tipo de retorno, e uma entrada para cada argumento ou variável local declarada, contendo o respetivo tipo.

5.1.2 Implementação

Na listagem que se segue apresentamos a estrutura de dados utilizada para representar e implementar cada *Tabela de Símbolos* criada, à qual demos o nome de *sym_t*:

```
typedef struct _sym_t sym_t;
struct _sym_t{
        ijava_table_type_t node_type;
        char* id;
        ijavatype_t type;
        int is_parameter;
        sym_t* next;
        sym_t* table_method;
        node_t* method_start;
};
typedef enum {
        CLASS_TABLE,
        METHOD_TABLE,
        VARIABLE,
        METHOD
} ijava_table_type_t;
```

Chamamos também a atenção do leitor para a definição do tipo $ijava_table_type_t$, apresentado a par da estrutura sym_t .

Lembramos ainda que os tipos $ijavatype_t$ e $node_t$ foram apresentados na definição das estruturas utilizadas na $\acute{A}rvore$ de Sintaxe Abstrata.

Passemos a detalhar um pouco mais a implementação apresentada.

Cada entrada da Tabela de Simbolos corresponde a uma estrutura do tipo $sym_{-}t$, sendo cada tabela constituída por uma ou mais entradas.

As nossas *Tabelas de Símbolos* não passam de simples listas ligadas, onde o primeiro elemento (a cabeça da lista) caracteriza a tabela, possuindo

informação relativa ao seu nome (que coincide com o nome da classe ou do método em questão), armazenado em id, e tipo, que se encontra em $node_type$. O tipo indica-nos se a entrada em questão corresponde a uma tabela de uma classe ou de um método, ou a uma declaração de um método ou de uma variável. Os diferentes elementos da lista encontram-se ligados pelo valor armazenado em next, um ponteiro para o próximo elemento da lista.

No caso da Tabela de Símbolos da classe, os restantes elementos vão corresponder a declarações de atributos ou métodos, possuindo no seu campo id o nome do atributo ou método declarado. Os que correspondem a declarações de atributos da classe vão possuir o seu tipo (int, boolean, etc) armazenado em type. Já os que correspondem a declarações de métodos referenciam a Tabela de Símbolos desse método através do campo table_method. Adicionalmente, estes últimos possuem também no campo method_start uma referência para o nó da Árvore de Sintaxe Abstrata onde se encontra a declaração do método.

Relativamente à *Tabela de Símbolos* de um método, o seu primeiro elemento está de acordo com o descrito anteriormente. Segue-se um elemento que contém o tipo de retorno do método, armazenado no campo *type*. Posteriormente encontram-se os argumentos do método, no caso de existirem, também eles com a informação relativa ao nome e tipo presente em *id* e *type*, respetivamente. Estes elementos possuem também o valor 1 no campo inteiro *is_parameter*, que indica que se tratam de parâmetros do método. Por fim, encontram-se as variáveis locais, pela ordem de declaração no método, sendo a informação relativa ao seu nome e tipo armazenada nos campos *id* e *type*, respetivamente.

5.1.3 Conclusão

Após a análise das estruturas de dados apresentadas podemos retirar algumas conclusões acerca das implicações que a escolha destas estruturas teve na implementação das *Tabelas de Símbolos*.

Em primeiro lugar é clara a utilização da mesma representação para estruturas conceptualmente distintas, como é o caso da tabela de símbolos da classe e dos métodos, ou das declarações de atributos e métodos de uma classe.

De facto, reconhecemos que a utilização de diferentes estruturas seria mais adequado de um ponto de vista conceptual, já que nos permitiria distinguir melhor os elementos que pretendemos representar, evitando a existência de campos não utilizados em algumas estruturas.

No entanto, optámos por manter esta representação dado que a consideramos mais simples ao nível da implementação, permitindo-nos generalizar algumas operações como a impressão dos elementos das diferentes tabelas, e até a procura de um elemento numa tabela.

5.2 Deteção de Erros Semânticos

6 Geração de Código

7 Apreciação do Trabalho